



## Clasificación Binaria con Regresión Logística

### Entender el problema

Nos piden un modelo que prediga si los clientes van a pagar o impagar para poder hacer acciones preventivas en algún caso (clientes ya existentes) o comerciales (créditos preconcedidos).

Parace muy claro, pero ¿qué significa impagar? ¿Es que mañana dejo de pagar una factura?¿Y si la repongo en menos de 30 días?¿Es tener una deuda a los seis meses sin pagar? Esto tenemos que aclararlo, no esperar a deducirlo del datatset (Aunque en estos ejemplos lo hagamos así). En nuestro caso nos contestan que es tener deudas pendientes de más de 2 años. Perfecto. Vamos con ello.

## Prepaaración Datos: Primer Vistazo

```
In [2]: import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import numpy as np

df = pd.read_csv('data/cs-training.csv')

df.head()
```

Out[2]:		Unnamed: 0	SeriousDlqin2yrs	Revolving Utilization Of Unsecured Lines	age	Numb 59DaysPastE
	0	1	1	0.766127	45	
	1	2	0	0.957151	40	
	2	3	0	0.658180	38	
	3	4	0	0.233810	30	
	4	5	0	0.907239	49	
	4					<b>+</b>

### Preparación Datos: Limpieza de datos

```
df.rename(columns = {'SeriousDlqin2yrs': 'target'}, inplace=True)
In [4]: sns.countplot(data=df, x='target');
          140000
          120000
          100000
           80000
           60000
           40000
           20000
                0
                                  0
                                                                    1
                                                 target
In [5]: df.info()
       <class 'pandas.core.frame.DataFrame'>
       RangeIndex: 150000 entries, 0 to 149999
       Data columns (total 12 columns):
           Column
                                                 Non-Null Count
                                                                 Dtype
       ---
           -----
                                                 -----
       0
           Unnamed: 0
                                                 150000 non-null
                                                                 int64
       1
           target
                                                 150000 non-null
                                                                 int64
           RevolvingUtilizationOfUnsecuredLines 150000 non-null float64
       2
                                                 150000 non-null int64
           NumberOfTime30-59DaysPastDueNotWorse 150000 non-null int64
           DebtRatio
                                                 150000 non-null float64
           MonthlyIncome
                                                 120269 non-null float64
       7
           NumberOfOpenCreditLinesAndLoans
                                                 150000 non-null int64
       8
           NumberOfTimes90DaysLate
                                                 150000 non-null
                                                                 int64
       9
           NumberRealEstateLoansOrLines
                                                 150000 non-null
                                                                 int64
       10 NumberOfTime60-89DaysPastDueNotWorse 150000 non-null int64
       11 NumberOfDependents
                                                 146076 non-null float64
       dtypes: float64(4), int64(8)
       memory usage: 13.7 MB
In [6]: # Nos cargamos columnas inutiles
        df.drop(['Unnamed: 0'], axis=1, inplace=True)
```

```
https://campusonline.thebridge.tech/ultra/courses/\_42\_1/outline/lti/launchFrame?toolHref=https:~2F~2F campusonline.thebridge.tech~2F webap...
```

# Nos cargamos duplicados

df.dropna(inplace=True)

In [7]:

### Preparación datos: Dividimos el dataset

```
In [8]: from sklearn.model_selection import train_test_split


X = df.drop(['target'], axis=1)
y = df['target']

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.20, rand)
```

#### MiniEDA: Matriz de correlación


Vamos a cargarnos algunas columnas que no estén muy relacionadas con el target (seria más aconsejable descartarlo haciendo un bivariante con test de hipótesis o usando pairplot, aunque hay que tener en cuenta que debe hacerse por partes porque pairplot es muy demandante y este dataset es grande en dato).

```
In [9]: df_eda = X_train.copy()
         df_eda["target"] = y_train.copy()
In [10]: np.abs(df_eda.corr()['target']).sort_values(ascending=False)
Out[10]: target
                                                  1.000000
         NumberOfTime30-59DaysPastDueNotWorse 0.127577
         NumberOfTimes90DaysLate
                                                 0.115376
                                                 0.102266
         NumberOfTime60-89DaysPastDueNotWorse
                                                 0.098259
         NumberOfDependents
                                                 0.046620
         NumberOfOpenCreditLinesAndLoans
                                                0.027646
         MonthlyIncome
                                                 0.018645
         NumberRealEstateLoansOrLines
                                                 0.004433
         DebtRatio
                                                 0.003192
         RevolvingUtilizationOfUnsecuredLines
                                                 0.002603
         Name: target, dtype: float64
In [11]: corr = np.abs(df_eda.corr()['target']).sort_values(ascending=False)
         # Features con menos de 0.1 de correlación vs el target
         bad_corr_feat = corr[corr < 0.05].index.values</pre>
         # Filtramos las columnas buenas
         df_eda.drop(columns=bad_corr_feat, inplace=True)
In [12]: plt.figure(figsize=(10,10))
         sns.heatmap(np.round(df_eda.corr(), 2),
                     vmin=-1,
                     vmax=1,
                     cmap=sns.diverging_palette(145, 280, s=85, l=25, n=7),
                     square=True,
                     linewidths=.5);
```



In [13]: sns.pairplot(df\_eda[[col for col in df\_eda.columns if "NumberOf" in col or col =

Out[13]: <seaborn.axisgrid.PairGrid at 0x7efc88ea5f10>




Te invito a usar nuestra librería de funciones gráficas para hacer un bivariante al estilo de las diagonales para las features con la mayor correlación.

```
In [14]:
         features_num = [col for col in df_eda.columns if "target" not in col]
         X_train = X_train[features_num].copy()
```

## Preparación de Features

```
In [15]: X_train.hist()
Out[15]: array([[<Axes: title={'center': 'age'}>,
                  <Axes: title={'center': 'NumberOfTime30-59DaysPastDueNotWorse'}>],
                 [<Axes: title={'center': 'NumberOfTimes90DaysLate'}>,
                  <Axes: title={'center': 'NumberOfTime60-89DaysPastDueNotWorse'}>]],
                dtype=object)
```



In [16]: X\_train.describe()

Out[16]

	age		Number Of Time 30-59 Days Past Due Not Worse	NumberOfTimes90DaysLate	Numk 89DaysPastE
	count	96215.000000	96215.000000	96215.000000	
	mean	51.285174	0.380211	0.210248	
	std	14.428079	3.479168	3.444867	
	min	0.000000	0.000000	0.000000	
	25%	41.000000	0.000000	0.000000	
	50%	51.000000	0.000000	0.000000	
	75%	61.000000	0.000000	0.000000	
	max	103.000000	98.000000	98.000000	
	4				<b>&gt;</b>

In [17]: X\_train[X\_train["NumberOfTime30-59DaysPastDueNotWorse"] > 0]

Out[17]:

•		age	Number Of Time 30-59 Days Past Due Not Worse	NumberOfTimes90DaysLate	Number Of Tin 89 Days Past Due Not V
	44650	41	2	1	
	27331	39	1	0	
	85530	53	1	0	
	106214	45	3	0	
	106548	47	2	0	
	•••				
	934	45	1	0	
	51349	30	3	0	
	55095	61	2	0	
	46514	78	1	0	
	1052	59	6	2	

16182 rows × 4 columns

**→** 

Podríamos hacer categóricas de las "veces en días vencidos", pero lo vamos a dejar así por espacio, no son variables para escalar necesariamente.

#### Modelo

Veremos los hiperparámetros (en este caso argumentos al constructor de la clase LogisticRegression) a medida que vayamos usando el modelo. Ahora tratemos "max\_iter":

max\_iter = numero de iteraciones del optimizador (recuerda que el gradiente descendente va probando combinaciones hasta que encuentra una que no mejora la función de minimización después de varios intentos), esta es otra forma de decirle el máximo número de combinaciones, de veces que se aplica el gradiennte descendente en caso de que no se llegue a la condición anterior (denominada tolerancia)

```
In [19]: print(log_reg.coef_)
    print(log_reg.intercept_)
    print(log_reg.classes_)
```

```
[[-0.02789161 0.50545547 0.43901075 -0.9050834 ]]
[-1.46237341]
[0 1]
```


### Feature importance

```
In [20]: intercept = log_reg.intercept_
         coefs = log_reg.coef_.ravel()
         features = pd.DataFrame(coefs, X_train.columns, columns=['coefficient']).copy()
         features['coefficient'] = np.abs(features['coefficient'])
         features.sort_values('coefficient', ascending=False).head()
```

Out[20]: coefficient 0.905083 NumberOfTime60-89DaysPastDueNotWorse NumberOfTime30-59DaysPastDueNotWorse 0.505455 NumberOfTimes90DaysLate 0.439011 0.027892

```
In [22]: stdevs = []
         for i in X_train.columns:
             stdev = df[i].std()
             stdevs.append(stdev)
         features["stdev"] = np.array(stdevs).reshape(-1,1)
         features["importance"] = features["coefficient"] * features["stdev"]
         features['importance_standarized'] = features['importance'] / y_train.std()
         features = features.sort_values('importance_standarized', ascending=True)
         plt.barh(features.index, features.importance standarized);
```

age



## **Accuracy**


Antes de usar el X\_test hay que hacerles las mismas transformaciones que le hayamos hecho al X train


```
In [23]: X_test = X_test[X_train.columns].copy()
In [24]: from sklearn.metrics import accuracy_score
         acc_train = round(accuracy_score(log_reg.predict(X_train), y_train), 3)
         acc_test = round(accuracy_score(log_reg.predict(X_test), y_test), 3)
         print("Accuracy train:", acc_train)
         print("Accuracy test:", acc_test)
        Accuracy train: 0.932
        Accuracy test: 0.929
         ¿Es buenos nuestro clasificador?
In [25]: y_train.value_counts(True)
Out[25]: target
          0
               0.93079
               0.06921
          Name: proportion, dtype: float64
In [26]: y_test.value_counts(True)
Out[26]: target
          0 0.929409
               0.070591
          Name: proportion, dtype: float64
         No, no lo es. Tendríamos que tratarlo de alguna forma mejor (Está muy desbalanceado) o
```

ver otras métricas

#### **Confusion matrix**

```
In [27]: from sklearn.metrics import confusion_matrix
         c_matrix = confusion_matrix(y_test, log_reg.predict(X_test))
         c_matrix_df = pd.DataFrame(c_matrix, columns = ['Pred_Pays', 'Pred_Default'],
                                   index = ['True_Pays', 'True_Default'])
         sns.heatmap(c_matrix_df, annot=True, fmt='g');
```





# **Classification report**

In [29]: from sklearn.metrics import classification\_report
 from pprint import pprint


```
print(classification_report(y_test, log_reg.predict(X_test)))
              precision
                            recall f1-score
                                                support
                              1.00
                                        0.96
           0
                   0.93
                                                  22356
                              0.03
           1
                   0.49
                                        0.05
                                                   1698
    accuracy
                                        0.93
                                                  24054
                              0.51
                                        0.51
   macro avg
                   0.71
                                                  24054
weighted avg
                   0.90
                              0.93
                                        0.90
                                                  24054
```

#### **ROC Curve**

AUROC: 0.69

```
In [30]: ### Usando matplotlib
from sklearn.metrics import roc_curve, auc
scores = log_reg.predict_proba(X_test)
fpr, tpr, thresholds = roc_curve(y_test, scores[:,1])
roc_auc = auc(fpr,tpr)
print("AUROC: %.2f" %(roc_auc))
plt.figure(figsize=(6, 5))
plt.plot(fpr, tpr, linewidth=2, color= "blue", label=f"ROC Logistic Reg (area = plt.plot([0, 1], [0, 1], 'k:', label="Random classifier's ROC curve")
plt.ylabel('True Positive Rate (Recall)')
plt.grid()
plt.axis([0, 1, 0, 1])
plt.legend(loc="lower right", fontsize=13)
```

Out[30]: <matplotlib.legend.Legend at 0x7efc7d9d8430>



In []: