



# Clasificación Multicategórica con Regresión Logística

### Entender el problema

Para mostrar la creación de un modelo multiclase y su evaluación vamos a tratar un problema en el que queremos detectar cuál es el sistema operativo de los usuarios que acceden a una dirección web específica (y que no es importante para el problema) en la que pasan un tiempo determinado, navegan a través de las páginas del site, realizan un conjunto de acciones y dejan una valoración de la misma. Encontrarás una variable "clase" que contiene el target, esta vez no tendrás que buscarlo, y que toma tres posibles valores en función del OS: Windows, Linux, Mac.

Creemos ese modelo predictor a partir de una regresión logística.

# Preparación Datos: Primer vistazo

```
In [2]: import pandas as pd
        import numpy as np
        from sklearn import linear model
        from sklearn import model selection
        from sklearn.metrics import classification report
        from sklearn.metrics import confusion_matrix
        from sklearn.metrics import accuracy score
        from sklearn.model_selection import train_test_split
        import matplotlib.pyplot as plt
        import seaborn as sns
        %matplotlib inline
        plt.rc('font', size=14)
        plt.rc('axes', labelsize=14, titlesize=14)
        plt.rc('legend', fontsize=14)
        plt.rc('xtick', labelsize=10)
        plt.rc('ytick', labelsize=10)
In [2]: df os = pd.read csv("data/usuarios win mac lin.csv")
        clases = {
            0: 'Windows',
            1: 'Linux',
```

```
2: 'Mac'
df_os.head()
```

#### Out[2]: duracion paginas acciones valor clase 0 2 2 7.0 8 1 21.0 2 6 6 2 2 57.0 2 4 4 2 3 101.0 3 6 12 2 4 109.0 2 6 12 2

```
In [3]: df_os.info()
```

<class 'pandas.core.frame.DataFrame'> RangeIndex: 170 entries, 0 to 169 Data columns (total 5 columns):


#	Column	Non-Null Count	Dtype				
0	duracion	170 non-null	float64				
1	paginas	170 non-null	int64				
2	acciones	170 non-null	int64				
3	valor	170 non-null	int64				
4	clase	170 non-null	int64				
dtypes: float64(1), int64(4)							

dtypes: float64(1),

memory usage: 6.8 KB

Mostramos el target, y su balanceo o desbalanceo


```
In [4]: df_os.clase.value_counts(True)
Out[4]: clase
        0
             0.505882
        2
             0.258824
             0.235294
        Name: proportion, dtype: float64
In [5]: sns.countplot(x = "clase", data = df_os, hue = "clase");
```



Windows es el sistema dominante y habrá que tenerlo en cuenta a la hora de las medidas y tendríamos que tenerlo en cuenta a la hora de modelar pero lo veremos en sesiones posteriores.

Echamos un vistazo y sólo eso a la distribución de las variables contínuas (o sea casi todas) y nos fijamos en escala y figura

In [6]: df\_os.hist();



Tiene pinta de que vamos a tener que escalar y hacer alguna transformación para "normalizar" las distribuciones.

# **Split**

Son muy pocos datos (170) pero vamos a hacer el split igual para que vayamos cogiendo el hábito. Además estratificamos sobre el target (pero ojo esto es para hacer más limpio el ejercicio, por ejemplo porque suponemos que es algo que se va a mantener debido al marketshare de cada sistema operativo)


```
train_set, test_set = train_test_split(df_os, test_size= 0.2, stratify= df_os["c
In [7]:
In [8]:
       train_set["clase"].value_counts(normalize = True)
Out[8]:
        clase
             0.507353
        2
             0.257353
             0.235294
        Name: proportion, dtype: float64
       test_set["clase"].value_counts(normalize = True)
In [9]:
Out[9]:
        clase
             0.500000
        2
             0.264706
             0.235294
        Name: proportion, dtype: float64
```


No es perfecto, pero prueba a hacer el split sin estratificar.

### Mini-EDA

Vamos a ver la correlación de las variables con el target, pero realmente son tan pocas que no vamos a quitar ninguna:

```
In [10]: train_set.drop("clase", axis = 1).hist()
    plt.show()
```






```
In [12]: features = train_set.drop("clase", axis = 1).columns.to_list()
    print(features)
```

['duracion', 'paginas', 'acciones', 'valor']

### Procesamiento de Features



In [14]: for col in features:
 test\_set[col] = test\_set[col].apply(np.log)
# Ojo ni Lo mires :-), pero tienes que aplicarle las mismas transformaciones que

In [15]: from sklearn.preprocessing import StandardScaler


scaler = StandardScaler()
scaler.fit(train\_set[features]) # Adaptamos el StandarScaler al Train, pero lueg
X\_train = pd.DataFrame(scaler.transform(train\_set[features]), columns = features
X\_test = pd.DataFrame(scaler.transform(test\_set[features]), columns = features)
X\_train.describe()

out[15]:		duracion	paginas	acciones	valor
	count	1.360000e+02	1.360000e+02	1.360000e+02	1.360000e+02
	mean	-1.632681e-16	-4.571507e-17	2.416368e-16	-3.395976e-16
	std	1.003697e+00	1.003697e+00	1.003697e+00	1.003697e+00
	min	-1.878357e+00	-8.947527e-01	-2.004312e+00	-2.501146e+00
	25%	-4.781410e-01	-8.947527e-01	-7.831545e-01	-7.258228e-01
	50%	-3.805922e-01	2.695613e-01	-1.268982e-02	2.121177e-01
	75%	7.491348e-01	2.695613e-01	7.577748e-01	6.482352e-01
	max	2.092503e+00	2.796035e+00	2.600971e+00	2.565771e+00

```
In [16]: y_train = train_set["clase"]
y_test = test_set["clase"]
```

#### Creamos el modelo

Si mostramos los coeficientes o pesos del modelo veremos que en realidad ha entrenado un modelo de regresión logística para cada clase como vimos en la sesión de teoría. Ha hecho un one-vs-rest



Ten en cuenta que estos coeficientes están aplicados sobre el logaritmo de las variables, aún así puedes ver que influye en la selección de cada clase.

Podemos ver las predicciones

Y las probabilidades para cada instancia, nos da un vector de tres probabilidades una para cada clase y puedes comprobar que escoge la de mayor probabilidad:

In [21]: clf.predict\_proba(X\_train)

```
Out[21]: array([[0.71646107, 0.27437523, 0.0091637],
                 [0.39537849, 0.10494105, 0.49968046],
                 [0.62557227, 0.33522879, 0.03919894],
                 [0.67445683, 0.3220793, 0.00346387],
                 [0.19058325, 0.1395637, 0.66985306],
                 [0.38953368, 0.10630614, 0.50416017],
                 [0.53891527, 0.45985535, 0.00122939],
                 [0.7588464 , 0.2158235 , 0.0253301 ],
                 [0.4699667, 0.05470718, 0.47532612],
                 [0.5911302 , 0.24190819 , 0.16696161],
                 [0.68803294, 0.30935528, 0.00261178],
                 [0.70699895, 0.28786924, 0.00513181],
                 [0.7488766, 0.21916641, 0.03195698],
                 [0.71317964, 0.2665672, 0.02025316],
                 [0.8085818 , 0.1752283 , 0.0161899 ],
                 [0.70441951, 0.21905707, 0.07652343],
                 [0.60960877, 0.38184107, 0.00855016],
                 [0.5761585, 0.38260778, 0.04123372],
                 [0.8861692, 0.06840359, 0.04542722],
                 [0.59449295, 0.3296183, 0.07588875],
                 [0.4812114, 0.49446707, 0.02432153],
                 [0.33802073, 0.52311691, 0.13886235],
                 [0.28764809, 0.11842382, 0.59392809],
                 [0.23603862, 0.06913009, 0.69483128],
                 [0.71754845, 0.26013093, 0.02232062],
                 [0.26014751, 0.59132396, 0.14852853],
                 [0.50099832, 0.30689334, 0.19210834],
                 [0.47953791, 0.40353689, 0.1169252],
                 [0.86703611, 0.09835412, 0.03460977],
                 [0.39537849, 0.10494105, 0.49968046],
                 [0.45930464, 0.53778153, 0.00291384],
                 [0.61745081, 0.3802173, 0.00233188],
                 [0.5807746, 0.35921815, 0.06000725],
                 [0.67632189, 0.27894137, 0.04473674],
                 [0.00780089, 0.00156449, 0.99063463],
                 [0.73843508, 0.25032618, 0.01123874],
                 [0.02979674, 0.00553675, 0.96466652],
                 [0.61403063, 0.38437365, 0.00159572],
                 [0.23603862, 0.06913009, 0.69483128],
                 [0.71317964, 0.2665672, 0.02025316],
                 [0.61254389, 0.36863563, 0.01882048],
                 [0.47110697, 0.18300289, 0.34589014],
                 [0.79349453, 0.11677401, 0.08973146],
                 [0.04730525, 0.01665552, 0.93603923],
                 [0.86737531, 0.10222483, 0.03039985],
                 [0.69382274, 0.29937659, 0.00680066],
                 [0.62475331, 0.06431709, 0.3109296],
                 [0.71877874, 0.26128953, 0.01993173],
                 [0.88960389, 0.10353151, 0.0068646],
                 [0.77569341, 0.1997806, 0.02452599],
                 [0.59343592, 0.30691105, 0.09965302],
                 [0.59902142, 0.24082103, 0.16015754],
                 [0.53320513, 0.40003568, 0.06675919],
                 [0.50788604, 0.49059776, 0.0015162],
                 [0.34714436, 0.1885783 , 0.46427733],
                 [0.63957779, 0.34987041, 0.0105518],
                 [0.00705896, 0.0015923, 0.99134874],
                 [0.58778296, 0.21827204, 0.193945]
                 [0.61674078, 0.38164656, 0.00161266],
                 [0.59385381, 0.31503242, 0.09111377],
```

```
[0.06636734, 0.01117606, 0.9224566],
[0.6848089 , 0.31378616, 0.00140494],
[0.63169918, 0.36444097, 0.00385985],
[0.5322331 , 0.2855693 , 0.1821976 ],
[0.64214636, 0.32266133, 0.03519231],
[0.43894227, 0.55273604, 0.00832169],
[0.64765417, 0.29223258, 0.06011325],
[0.22776964, 0.07036786, 0.7018625],
[0.36116676, 0.20856257, 0.43027067],
[0.5506327, 0.36316346, 0.08620384],
[0.53554273, 0.44177985, 0.02267743],
[0.00344511, 0.00249393, 0.99406096],
[0.64606836, 0.27790081, 0.07603084],
[0.21068015, 0.10215062, 0.68716924],
[0.79418324, 0.20418257, 0.0016342],
[0.66882202, 0.32766696, 0.00351102],
[0.06786154, 0.01111417, 0.92102429],
[0.46483193, 0.18565872, 0.34950934],
[0.87089303, 0.12759693, 0.00151004],
[0.69287044, 0.2777135, 0.02941607],
[0.03278126, 0.01800493, 0.94921381],
[0.47692077, 0.40570798, 0.11737125],
[0.89218646, 0.08983905, 0.01797449],
[0.54403362, 0.44143035, 0.01453603],
[0.38953368, 0.10630614, 0.50416017],
[0.23170608, 0.06977543, 0.69851849],
[0.39537849, 0.10494105, 0.49968046],
[0.68424679, 0.30650357, 0.00924964],
[0.71317964, 0.2665672, 0.02025316],
[0.57183679, 0.27141581, 0.1567474],
[0.63368306, 0.3556308, 0.01068615],
[0.61471318, 0.35645396, 0.02883286],
[0.72360603, 0.22135295, 0.05504102],
[0.06786154, 0.01111417, 0.92102429],
[0.38953368, 0.10630614, 0.50416017],
[0.33079372, 0.29482187, 0.37438441],
[0.08614733, 0.01437601, 0.89947666],
[0.49812597, 0.44129006, 0.06058397],
[0.77615201, 0.20398026, 0.01986773],
[0.24189695, 0.10684913, 0.65125391],
[0.89206067, 0.06981049, 0.03812884],
[0.51303871, 0.47714706, 0.00981424],
[0.67204862, 0.31466411, 0.01328727],
[0.0180746 , 0.00185707, 0.98006834],
[0.71920575, 0.26565678, 0.01513747],
[0.28112668, 0.1711979, 0.54767542],
[0.89620657, 0.07365821, 0.03013522],
[0.05920629, 0.0240568, 0.91673691],
[0.63987963, 0.28300272, 0.07711765],
[0.39271884, 0.5162229 , 0.09105826],
[0.88094317, 0.10823101, 0.01082582],
[0.61911031, 0.3693165, 0.01157319],
[0.40055995, 0.55955312, 0.03988693],
[0.48208263, 0.49181294, 0.02610443],
[0.47056177, 0.43171186, 0.09772637],
[0.06636734, 0.01117606, 0.9224566],
[0.72978203, 0.25554448, 0.01467349],
[0.74571389, 0.23479339, 0.01949272],
[0.65470904, 0.22672355, 0.11856742],
[0.79463876, 0.1910897, 0.01427155],
```

```
[0.80869267, 0.13652576, 0.05478157],
[0.31528418, 0.20103705, 0.48367877],
[0.51722419, 0.47918926, 0.00358654],
[0.37713872, 0.45040324, 0.17245804],
[0.07225801, 0.02504117, 0.90270082],
[0.61855717, 0.36284948, 0.01859335],
[0.31050661, 0.16136695, 0.52812643],
[0.65470904, 0.22672355, 0.11856742],
[0.03908222, 0.00266026, 0.95825752],
[0.02979674, 0.00553675, 0.96466652],
[0.7590572, 0.20212666, 0.03881615],
[0.06786154, 0.01111417, 0.92102429],
[0.05692699, 0.036267, 0.90680601],
[0.65970069, 0.33552315, 0.00477616],
[0.03145444, 0.00255682, 0.96598874],
[0.57819641, 0.33979744, 0.08200616]])
```

#### 0.7279411764705882

En este caso vemos que el accuracy es superior a la contribución de la clase mayoritaria, no tiene mala pinta (pero recuerda que es el train). No vamos a ver el test, antes vamos a usar la validación cruzada y luego veremos las métricas para multiclase.

### Validamos el modelo

Usemos la validación cruzada no tanto para comparar con otros modelos, que no tenemos, sino como para adelantarnos a la evaluación con el test y de nuevo ir cogiendo hábito.

```
In [23]: from sklearn import model_selection
    name='Logistic Regression'
    cv_results = model_selection.cross_val_score(clf, X_train, y_train, cv=5, scorin
    msg = "%s: %f (%f)" % (name, cv_results.mean(), cv_results.std())
    print(cv_results)
    print(msg)

[0.64285714 0.62962963 0.666666667 0.66666667 0.77777778]
```

```
[0.64285/14 0.62962963 0.6666666/ 0.6666666/ 0.//////8]
Logistic Regression: 0.676720 (0.052496)
```

Ya vemos que sale menor que el 72% del train.

#### Evaluación del modelo

#### Matriz de confusion


A mano, como un dataframe a partir de los datos que nos da el confusion\_matrix de sklearn:


Out[26]:		Predicho 0	Predicho 1	Predicho 2
	Real 0	14	0	3
	Real 1	3	5	0
	Real 2	0	0	9

Gráficamente:

```
In [27]: ConfusionMatrixDisplay.from_predictions(y_test, y_pred)
```

Out[27]: <sklearn.metrics.\_plot.confusion\_matrix.ConfusionMatrixDisplay at 0x7fb64e63f07
0>





# Métricas MACRO y MICRO

```
In [29]: micro_prec = precision_score(y_test, y_pred, average="micro")
         print("MICRO PRECISION:", micro_prec)
         macro_prec = precision_score(y_test, y_pred, average="macro")
         print("MACRO PRECISION:", macro_prec)
         micro_rec = recall_score(y_test, y_pred, average="micro")
         print("MICRO RECALL:", micro rec)
         macro_rec = recall_score(y_test, y_pred, average="macro")
         print("MACRO RECALL:", macro_rec)
         micro_acc = accuracy_score(y_test, y_pred)
         print("MICRO ACCURACY:", micro acc)
        MICRO PRECISION: 0.8235294117647058
        MACRO PRECISION: 0.8578431372549019
        MICRO RECALL: 0.8235294117647058
        MACRO RECALL: 0.8161764705882352
        MICRO ACCURACY: 0.8235294117647058
In [30]: acierto = accuracy_score(y_test, y_pred)
         error = 1 - acierto
         print("Acierto:", round(acierto*100, 2), "%")
         print("Error:", round(error*100, 2), "%")
        Acierto: 82.35 %
```

Informe de Resultados

Error: 17.65 %

```
In [31]: from sklearn.metrics import classification report
        print(classification_report(y_test, y_pred))
                  precision recall f1-score
                                             support
                0
                      0.82
                              0.82
                                       0.82
                                                  17
                      1.00
                              0.62
                1
                                       0.77
                                                  8
                      0.75
                              1.00
                                                  9
                                       0.86
                                       0.82
                                                  34
          accuracy
                    0.86 0.82 0.82
                                                  34
         macro avg
      weighted avg
                      0.85
                               0.82
                                      0.82
                                                  34
```

#### Clasificación de nuevos registros

Para terminar veamos como sería la predicción para un usuario que dedica una duración de 1, ve 1 página, ejecuta 1 acción y valora con 2 el site